

Detección de defectos superficiales en aceros haciendo uso de Deep Learning

Por: Luis David Morales Aguilar

1. Contexto de aplicación

El acero es uno de los materiales más utilizados en la industria de manufactura de materiales metálicos, debido a las diversas propiedades físicas que presenta y a que es económicamente viable su producción [1]. La necesidad de productos con altos estándares de calidad para cumplir sus funciones mecánicas, requiere la detección precisa de defectos en el material [2]. Esto garantiza la seguridad y la fiabilidad general al utilizar estos materiales en los distintos campos de aplicación, como por ejemplo infraestructura, sistemas de transporte, tecnología, entre otros. Por otro lado, la detección temprana de estos defectos evita la afectación de la productividad de un proceso, reduciendo los costos por pérdidas en producción. Un área de particular importancia es la inspección superficial de los materiales, donde la presencia de defectos podría indicar problemas que hagan inviable la comercialización del producto.

La detección de defectos superficiales en la industria del acero es un reto en general. Los sistemas de inspección se basan en cámaras u otro tipo de sensores de imagen que otorgan buenas fotografías en las condiciones de trabajo impuestas. Estos datos deben ser analizados en tiempo real para mantener un control estricto del proceso y reducir el número de productos fabricados defectuosamente. Sin embargo, el análisis en tiempo real es difícil de lograr debido a que las velocidades de producción del acero comúnmente se encuentran entre 1 y 100 m/s dependiendo del proceso [3]. Para poder realizar una caracterización de los defectos superficiales del acero bajo estas condiciones, se requiere el uso de un buen hardware y un algoritmo de clasificación eficiente.

Los métodos de *Deep Learning* se pueden utilizar para este tipo de aplicaciones y ofrecen ventajas con respecto a los métodos tradicionales de *Machine Learning*, como una mayor precisión en predicción. Esto ha revolucionado el campo de inspección de superficies en los últimos años llevado a sustituir rápidamente los métodos tradicionales por diferentes metodologías de *Deep Learning* [4]–[6].

2. Objetivo de machine learning

Objetivo general:

Desarrollar un modelo de Deep Learning para la detección y clasificación de defectos superficiales en el procesamiento de aceros usando un dataset de imágenes que incluye los defectos más comunes de estos materiales durante su proceso de manufactura.

Objetivos específicos:

- Diseñar una arquitectura basada en redes neuronales convolucionales que se ajuste a las características requeridas para la predicción y clasificación de defectos en imágenes de superficies metálicas.
- Evaluar el desempeño del modelo utilizando métricas estándar en aplicaciones de clasificación de defectos, y ajustar la arquitectura en función de los resultados obtenidos.
- Comparar el desempeño del modelo propuesto con el de los modelos preentrenados más utilizados en el campo de la clasificación de defectos en superficies metálicas.

3. Dataset

El conjunto de datos [7] está compuesto por 7096 imágenes de superficies de acero, obtenidas durante el proceso de fabricación. Las imágenes se almacenan en una carpeta con sus respectivos nombres, mientras que el archivo CSV asociado contiene dos columnas: la primera con los nombres de las imágenes y la segunda con la clasificación correspondiente.

La clasificación está representada por un número entero del 1 al 4, asignado de la siguiente manera:

- Clase 1: Sin defectos superficiales
- Clase 2: Scratches o rayones
- Clase 3: Inclusiones no metálicas
- Clase 4: Escamas de laminación

4. Métricas de desempeño

Maching learning:

Las métricas seleccionadas para evaluar el desempeño del modelo en la detección y clasificación de defectos son las siguientes:

- Precisión: Se define como el porcentaje de predicciones correctas sobre el total de elementos predichos. Un valor alto es deseado cuando los falsos positivos son penalizados severamente o son indeseables en el proceso. Para la clasificación que se llevará a cabo, un valor superior a 0,75 se considera adecuado.
- Recall: Esta métrica mide la capacidad del modelo para identificar correctamente los valores positivos verdaderos. Es crucial cuando los falsos negativos resultan costosos en el proceso. Se espera que un buen modelo logre valores superiores a 0,8.
- F1-Score: Es la combinación entre la precisión y el recall, y evalúa la capacidad predictiva del modelo, considerando su desempeño en cada clase individualmente, en lugar de su desempeño global.
- Coeficiente de Dice: Comúnmente utilizado en problemas de segmentación de imágenes, cuantifica qué tan bien se alinea la región predicha con la región verdadera en la imagen. Un coeficiente de Dice superior a 0,85 se considera generalmente aceptable. Esta métrica es ampliamente utilizada en la detección de defectos en superficies metálicas [2].

Negocio:

La implementación de un modelo de este tipo en una empresa de alta producción de acero puede generar un aumento significativo en los niveles de productividad, ya que la detección de defectos en el material podría realizarse de manera in-situ, mejorando el tiempo de respuesta para la solución de problemas en la planta.

Además, la capacidad de clasificar los defectos permite acotar las posibles causas de los mismos, facilitando la implementación de soluciones en el proceso. Resolver estos inconvenientes contribuiría a mejorar la calidad del material producido y, en consecuencia, aumentar la

confiabilidad del producto. Un incremento en la confiabilidad se traduciría, potencialmente, en una mayor demanda del material comercializado.

Por otro lado, la cantidad de pérdidas por material rechazado o devuelto a causa de defectos disminuiría considerablemente, dependiendo del nivel de precisión alcanzado por el modelo, lo que implicaría un beneficio económico para la empresa que lo implemente.

5. Resultados previos

Ref	Título	Modelo Deep Learning	Datos	Métricas
[2]	Automated Surface Defect Detection in Metals: A Comparative Review of Object Detection and Semantic Segmentation Using Deep Learning	YOLOv5, U-Net	1800 imágenes con 6 diferentes tipos de defectos.	Precisión, Recall y Dice con valores entre 0,77 y 0,88
[5]	Metal Defect Classification Using Deep Learning	Estructura propia de redes convolucionales	9390 imágenes para entrenamiento, 1657 para validación y 1950 para test. 4 clases de defectos diferentes.	Pérdida, exactitud, precisión, Recall con valores entre 0,7 y 0,95.
[8]	A deep learning model for steel surface defect detection	YOLOv5s	1800 imágenes con 6 diferentes tipos de defectos	Precisión, recall, mAP con valores entre 0,7 y 0,8

6. Referencias

- [1] M. Bordigoni and C. Francois, "Steel Intensity as a Dynamic Function of Economic Growth," *Energy Expect. Uncertain.*, pp. 43–44, 2016.
- [2] R. Usamentiaga, D. G. Lema, O. D. Pedrayes, and D. F. Garcia, "Automated Surface Defect Detection in Metals: A Comparative Review of Object Detection and Semantic Segmentation Using Deep Learning," *IEEE Trans. Ind. Appl.*, vol. 58, no. 3, pp. 4203–4213, 2022, doi: 10.1109/TIA.2022.3151560.
- [3] H. Jia, Y. L. Murphey, J. Shi, and T.-S. Chang, "An Intelligent Real-time Vision System for Surface Defect Detection," 2004, doi: 10.1109/ICPR.2004.1334512.
- [4] S. Jezek, M. Jonak, R. Burget, P. Dvorak, and M. Skotak, "Deep learning-based defect detection of metal parts: Evaluating current methods in complex conditions," *Int. Congr. Ultra Mod. Telecommun. Control Syst. Work.*, vol. 2021-Octob, pp. 66–71, 2021, doi: 10.1109/ICUMT54235.2021.9631567.
- [5] A. T. Prihatno, I. B. K. Y. Utama, J. Y. Kim, and Y. M. Jang, "Metal Defect Classification Using Deep Learning," *Int. Conf. Ubiquitous Futur. Networks, ICUFN*, vol. 2021-Augus, pp. 389–393, 2021, doi: 10.1109/ICUFN49451.2021.9528702.
- [6] Q. Jiang, D. Tan, Y. Li, S. Ji, C. Cai, and Q. Zheng, "Object detection and classification of metal polishing shaft surface defects based on convolutional neural network deep learning," *Appl. Sci.*, vol. 10, no. 1, 2020, doi: 10.3390/app10010087.
- [7] Severstal, "Severstal: Steel Defect Detection." <https://www.kaggle.com/competitions/severstal-steel-defect-detection>.
- [8] Z. Li, X. Wei, M. Hassaballah, Y. Li, and X. Jiang, "A deep learning model for steel surface defect detection," *Complex Intell. Syst.*, vol. 10, no. 1, pp. 885–897, 2024, doi: 10.1007/s40747-023-01180-7.